بلاندر گارد: تولید تفسیر آموزشی شطرنج با مدل زبانی کوچک و تحلیل موتور شطرنج

سیدعلی حسینی‌نسب
دانشگاه شهید بهشتی، تهران، ایران
seyed123ali123@gmail.com
استاد راهنما: مریم طهماسبی

شهریور ۱۴۰۵

چکیده

در این گزارش، سامانه‌ی **بلاندر گارد** برای تولید توضیح آموزشی درباره‌ی حرکت‌های شطرنج معرفی می‌شود. ایده‌ی اصلی سامانه، جداسازی «محاسبه‌ی قابل اعتماد شطرنج» از «بیان طبیعی و قابل فهم» است. موتور Stockfish دو وضعیت پیش و پس از حرکت را تحلیل می‌کند و یک استخراج‌گر قطعی، تغییرات مادی و موقعیتی را از روی صفحه به دست می‌آورد. سپس یک مدل زبانی کوچک که با متون کلاسیک شطرنج سازگار شده است، این شواهد را به توضیحی کوتاه و مناسب بازیکن مبتدی تبدیل می‌کند.

پیکره‌ی سازگارسازی شامل حدود ۸٫۲ میلیون توکن از کتاب‌های آموزشی شطرنج است. مدل پایه‌ی Qwen3-1.7B با روش QLoRA تنظیم و برای اجرای محلی به قالب GGUF تبدیل شده است. برای ارزیابی، ۶۰ وضعیت در سه سطح مبتدی، متوسط و پیشرفته انتخاب و خروجی هفت مدل با داور محلی Gemma 4 12B سنجیده شد. بهترین میانگین کل متعلق به GPT-5.5 با امتیاز ۳۱٫۷ از ۱۰ بود، در حالی که مدل شطرنج تنظیم‌شده امتیاز ۴۹٫۲ را به دست آورد. نتیجه نشان می‌دهد که روانی متن به‌تنهایی نشانه‌ی صحت شطرنجی نیست و برای ساخت یک مربی قابل اعتماد، آموزش وابسته به وضعیت و اتصال دقیق‌تر به شواهد موتور ضروری است.

واژگان کلیدی: هوش مصنوعی شطرنج، مدل زبانی کوچک، تولید زبان طبیعی، هوش مصنوعی توضیح‌پذیر، Stockfish، مدل زبانی به‌عنوان داور

۱ مقدمه

موتورهای امروزی شطرنج از قوی‌ترین بازیکنان انسانی دقیق‌ترند، اما خروجی آن‌ها معمولاً به امتیاز سانتی‌پیاده، وضعیت مات و چند دنباله‌ی پیشنهادی محدود می‌شود. این اطلاعات برای یک استاد شطرنج مفید است، ولی یک بازیکن مبتدی غالباً نمی‌داند چرا یک حرکت خوب یا بد بوده است. در سوی دیگر، مدل‌های زبانی می‌توانند توضیحی روان بنویسند، اما ممکن است مهره‌ای را در خانه‌ای نادرست تصور کنند، یک تاکتیک وجودنداشته را بیان کنند یا جهت برتری را اشتباه تشخیص دهند.

مسئله‌ی اصلی این پژوهش تولید تفسیری است که هم‌زمان سه ویژگی داشته باشد:

۱. با ارزیابی و دنباله‌های موتور شطرنج سازگار باشد؛

۲. برای یادگیری بازیکن، کوتاه، روشن و علت‌محور باشد؛

۳. روی سخت‌افزار مصرف‌کننده و بدون وابستگی اجباری به سرویس ابری اجرا شود.

بلاندر گارد برای رسیدن به این هدف از یک معماری ترکیبی استفاده می‌کند. موتور شطرنج وظیفه‌ی محاسبه را بر عهده دارد، قواعد قطعی تغییرات صفحه را استخراج می‌کنند و مدل زبانی تنها مسئول تبدیل این شواهد به زبان طبیعی است. این جداسازی امکان بررسی مستقل خطای هر جزء را فراهم می‌کند.

۲ کارهای مرتبط

تولید خودکار تفسیر شطرنج ابتدا به‌صورت یک مسئله‌ی تولید زبان متکی بر ویژگی‌های صفحه بررسی شد. جهمتانی و همکاران [۹] مجموعه‌ای شامل بیش از ۲۹۸ هزار جفت حرکت و تفسیر ارائه کردند و از اطلاعات حرکت، تهدید و امتیاز موتور برای تولید متن استفاده کردند. این پژوهش نشان داد که انتخاب محتوای مناسب به اندازه‌ی روانی جمله اهمیت دارد.

زنگ و همکاران [۱۸] یک موتور عصبی شطرنج را همراه با مولد متن آموزش دادند. بازنمایی پیوسته‌ی موتور برای پیش‌بینی حرکت و وضعیت‌های آینده به مدل کمک می‌کرد و تفسیرها در پنج گروه توصیف، کیفیت، زمینه، مقایسه و برنامه تولید می‌شدند. در مقابل، بلاندر گارد موتور را از مولد جدا نگه می‌دارد تا بتوان Stockfish و مدل زبان را مستقل از هم جایگزین یا ارزیابی کرد.

نزدیک‌ترین معماری به این پروژه متعلق به لی و همکاران [۱۱] است. آن‌ها سیگنال‌های یک موتور نمادین را به‌صورت برچسب‌های کنترلی به مدل زبان می‌دهند. تفاوت اصلی آن است که روش آن‌ها با داده‌های جفت‌شده‌ی وضعیت و تفسیر آموزش می‌بیند، ولی مدل بلاندر گارد دانش زبانی خود را از کتاب‌های بدون برچسب می‌آموزد و هنگام استنتاج، شواهد Stockfish را در قالب یک درخواست متنی ساخت‌یافته دریافت می‌کند.

کیم و همکاران [۱۰] در چارچوب CCC مفاهیمی مانند امنیت شاه، تحرک و پیاده‌ی رونده را از مدل خبره استخراج و بر اساس اهمیت اولویت‌بندی می‌کنند. آن‌ها همچنین معیار GCC-Eval را برای ارزیابی چندبعدی تفسیر ارائه می‌کنند. این پژوهش از نظر ترکیب خبره و مدل زبان و نیز استفاده از داور زبانی به بلاندر گارد نزدیک است، اما استخراج ویژگی در پروژه‌ی حاضر قطعی و مبتنی بر مقایسه‌ی دو صفحه است.

کوی و همکاران [۴] مسئله را از توضیح پس از حرکت به «بیان راهبرد شطرنج» گسترش می‌دهند. روش آن‌ها یک درخت شاخه‌دار از پاسخ‌های محتمل موتور می‌سازد و سودمندی توضیح را با امکان اجرای راهبرد می‌سنجد. این کار نشان می‌دهد که ارزیابی فقط روی خط اصلی کافی نیست و توضیح مفهومی بدون دنباله‌ی عینی می‌تواند مبهم باشد.

در حوزه‌ی توضیح‌پذیری موتور نیز پالسن و بیورنسن [۱۳] نشان داده‌اند که می‌توان مفاهیم قابل تشخیص انسانی را از بازنمایی یک عامل شطرنج قدرتمند بازیابی کرد. مرور بیورنسن [۱] نیز شطرنج را محیط مناسبی برای مطالعه‌ی عامل‌های توضیح‌پذیر می‌داند.

جدول ۱: مقایسه‌ی فشرده‌ی رویکردهای نزدیک

پژوهش	منبع اتصال به شطرنج	تفاوت اصلی با بلاندر گارد
جهمتانی و همکاران	ویژگی‌های دستی و امتیاز موتور	آموزش نظارت‌شده با تفسیرهای جفت‌شده
زنگ و همکاران	موتور عصبی مشترک	آموزش مشترک بازی و تولید متن
لی و همکاران	برچسب‌های کنترلی موتور	نزدیک‌ترین معماری، ولی متکی بر داده‌ی جفت‌شده
کیم و همکاران	مفاهیم اولویت‌بندی‌شده	استخراج مفهوم یادگرفته‌شده و مولد بزرگ
بلاندر گارد	چند خط Stockfish و اختلاف دو صفحه	مدل کوچک محلی و ویژگی‌های قطعی و قابل بازرسی

۳ آماده‌سازی پیکره‌ی آموزشی

۱.۳ منابع متنی

پیکره‌ی دامنه از کتاب‌های آموزشی کلاسیک زیر ساخته شد:

- *Chess of Game The* از زیگبرت تاراش [۱۷]؛
- *Tournament، Chess International Zurich* ۱۹۵۳ از داوید برونشتاین [۲]؛
- *Tal Mikhail of Games and Lfie The* از میخائیل تال [۱۶]؛
- *Chess Your Reassess to How* از جرمی سیلمن [۱۴]؛
- *Move by Move Chess: Logical* از ایروینگ چرنف [۳].

این کتاب‌ها سبک‌های متفاوتی از آموزش را پوشش می‌دهند: اصول کلاسیک، عدم‌تعادل‌های پوزیسیونی، بازی تهاجمی، تحلیل مسابقه و توضیح حرکت‌به‌حرکت. متن کتاب‌ها با pypdf استخراج شد. شکست کلمه در انتهای سطر اصلاح، فاصله‌های نامنظم یکسان و بخش‌های خالی حذف شدند. خروجی پاک‌سازی‌شده تقریباً ۸٫۲ میلیون توکن دارد.

۲.۳ سازگارسازی مدل

مدل پایه Qwen3-1.7B است. برای کاهش هزینه‌ی حافظه از QLoRA [۵] با رتبه‌ی ۱۶، ضریب مقیاس ۳۲ و افت ۰۵٫۰ استفاده شد. آداپتورها روی نگاشت‌های پرس‌وجو و مقدار اعمال شدند. طول قطعه‌ی آموزشی ۲۵۶ توکن بود. پس از آموزش، آداپتورها با مدل پایه ادغام و مدل به قالب GGUF تبدیل شد. نسخه‌ی ارزیابی‌شده از کوانتیزه‌سازی Q8_0 و چارچوب llama.cpp [۷] استفاده می‌کند.

نکته‌ی مهم این است که پیکره‌ی کتاب‌ها شامل جفت «وضعیت صفحه–تفسیر مرجع» نیست. بنابراین تنظیم مدل بیشتر سبک نوشتار و واژگان شطرنج را آموزش می‌دهد و تضمینی برای استدلال صحیح روی یک وضعیت جدید ایجاد نمی‌کند. این محدودیت در نتایج کمی نیز دیده می‌شود.

۴ خط لوله‌ی تحلیل مبتنی بر موتور

۱.۴ تحلیل دو وضعیت

ورودی پژوهش دو رشته‌ی FEN است: صفحه‌ی قبل از حرکت و صفحه‌ی بعد از حرکت. هر وضعیت با Stockfish [۱۵] تا عمق ۱۷ و با سه خط اصلی تحلیل می‌شود. برای هر وضعیت، امتیاز سانتی‌پیاده از دید سفید، احتمال برد تبدیل‌شده، بهترین حرکت، دنباله‌های اصلی و وضعیت مات نگهداری می‌شود.

اگر ارزیابی پیش و پس از حرکت را به‌ترتیب E_b و E_a بنامیم، تغییر از دید بازیکنی که حرکت کرده است برابر است با:

$$\Delta = \begin{cases} E_a - E_b & \text{اگر سفید حرکت کرده باشد،} \\ E_b - E_a & \text{اگر سیاه حرکت کرده باشد.} \end{cases} \tag{۱}$$

این تغییر برای دسته‌بندی کیفی حرکت به عادی، خوب، عالی، اشتباه، عدم‌دقت یا بلاندر به کار می‌رود. وضعیت مات جداگانه بررسی می‌شود تا مقدارهای بسیار بزرگ موتور با خطای عادی اشتباه نشوند.

۲.۴ استخراج ویژگی‌های قطعی

با استفاده از python-chess [۶] حرکت انجام‌شده از میان حرکت‌های قانونی بازیابی می‌شود. سپس دو صفحه برای هر دو رنگ مقایسه می‌شوند. ویژگی‌های اصلی عبارت‌اند از:

- **ایمنی مهره:** مهره‌ای که پس از حرکت مورد حمله است ولی مدافع ندارد؛
- **ساختار پیاده:** ایجاد پیاده‌ی دوبله، منفرد یا عقب‌مانده؛
- **امنیت شاه:** از دست رفتن حق قلعه، افزایش فشار مستقیم یا ضعیف شدن سپر پیاده‌ای؛
- **کنترل مرکز:** تغییر کنترل خانه‌های e4، e5، d4 و d5؛
- **توسعه:** باقی ماندن فیل یا اسب روی خانه‌ی آغازین؛
- **زمینه‌ی تاکتیکی:** بهترین حرکت پیش و پس از انتقال، فرصت ازدست‌رفته و مات اجباری.

خروجی این مرحله یک رکورد ساخت‌یافته شامل دو FEN، ارزیابی‌ها، سه خط اصلی، حرکت بازی‌شده، بهترین حرکت‌ها، دسته‌ی کیفیت، وضعیت مات و تغییرات ویژگی برای سفید و سیاه است.

۳.۴ ساخت درخواست و تولید تفسیر

رکورد ساخت‌یافته به یک درخواست محدودشده تبدیل می‌شود. مدل باید فقط دو یا سه جمله‌ی کوتاه بنویسد، از اصطلاحاتی مانند «موتور» یا مقدار ارزیابی استفاده نکند، خط محاسبه را نقل نکند و علت حرکت را با زبان ساده توضیح دهد. شواهد عددی و دنباله‌های موتور در ورودی وجود دارند، اما فقط برای استدلال مدل هستند و نباید مستقیماً در پاسخ ظاهر شوند.
دو روش استنتاج پیاده‌سازی شده است:

۱. **روش تک‌مرحله‌ای:** همه‌ی شواهد در یک درخواست به مدل داده و پاسخ نهایی دریافت می‌شود؛

۲. **روش زنجیره‌ای:** مدل ابتدا دو وضعیت را جداگانه توصیف می‌کند و سپس با استفاده از توصیف‌های میانی و شواهد موتور، توضیح نهایی را می‌سازد.

روش اول سریع‌تر است و روش دوم امکان مقایسه‌ی صریح‌تر را فراهم می‌کند، ولی به سه فراخوانی مدل نیاز دارد.

۵ ساخت مجموعه‌ی ارزیابی

مجموعه‌ی ارزیابی از بازی‌های استاندارد امتیازدار لیچس در فوریه‌ی ۲۰۱۳ ساخته شد [۱۲]. بازی‌های کوتاه‌تر از ۳۰ نیم‌حرکت کنار گذاشته شدند. گروه‌بندی با میانگین ریتینگ دو بازیکن انجام شد:

- مبتدی: میانگین کمتر از ۱۲۰۰؛
- متوسط: میانگین ۱۲۰۰ تا ۱۷۹۹؛
- پیشرفته: میانگین ۱۸۰۰ یا بیشتر.

از هر گروه ۲۰ انتقال صفحه به‌صورت دستی انتخاب شد؛ در نتیجه معیار نهایی ۶۰ ردیف دارد. هر ردیف شامل شناسه‌ی پایدار، دو FEN، حرکت، درخواست مبتنی بر موتور، دسته‌ی سختی و یک تفسیر مرجع پالایش‌شده است. شناسه و دسته برای تطبیق یک‌به‌یک خروجی هر مدل با مرجع استفاده می‌شوند.

۶ روش ارزیابی با مدل داور

هفت مدل پاسخ‌دهنده روی درخواست‌های یکسان آزمایش شدند: مدل شطرنج تنظیم‌شده، Llama-3.2-3B-Instruct، Gemma-3-12B-Instruct، Gemini-3.5-Flash، GPT-5.5، Grok-4.3 و Qwen3.7-Plus. مدل‌های محلی از طریق llama-server و مدل‌های میزبانی‌شده از طریق یک رابط سازگار با OpenAI فراخوانی شدند.
برای داوری از مدل محلی Gemma 4 12B [۸] استفاده شد. این روش در خانواده‌ی ارزیابی «مدل زبانی به‌عنوان داور» قرار می‌گیرد [۱۹]. دما صفر، استدلال داخلی غیرفعال و خروجی به یک شِمای JSON محدود شد. داور پاسخ نامزد را فقط با مرجع همان ردیف مقایسه و پنج امتیاز صحیح بین صفر تا ده تولید می‌کند:

- **صحت:** سازگاری ادعاهای اصلی شطرنج با مرجع؛
- **وفاداری:** پرهیز از جزئیات یا تاکتیک‌های پشتیبانی‌نشده؛
- **سودمندی:** انتقال علت، پیامد یا درس آموزشی مرجع؛
- **پیروی از دستور:** مرتبط و مناسب بودن پاسخ برای یادگیرنده؛
- **روانی:** دستور زبان و وضوح، مستقل از درستی شطرنجی.

امتیاز کل به‌صورت زیر محاسبه می‌شود:

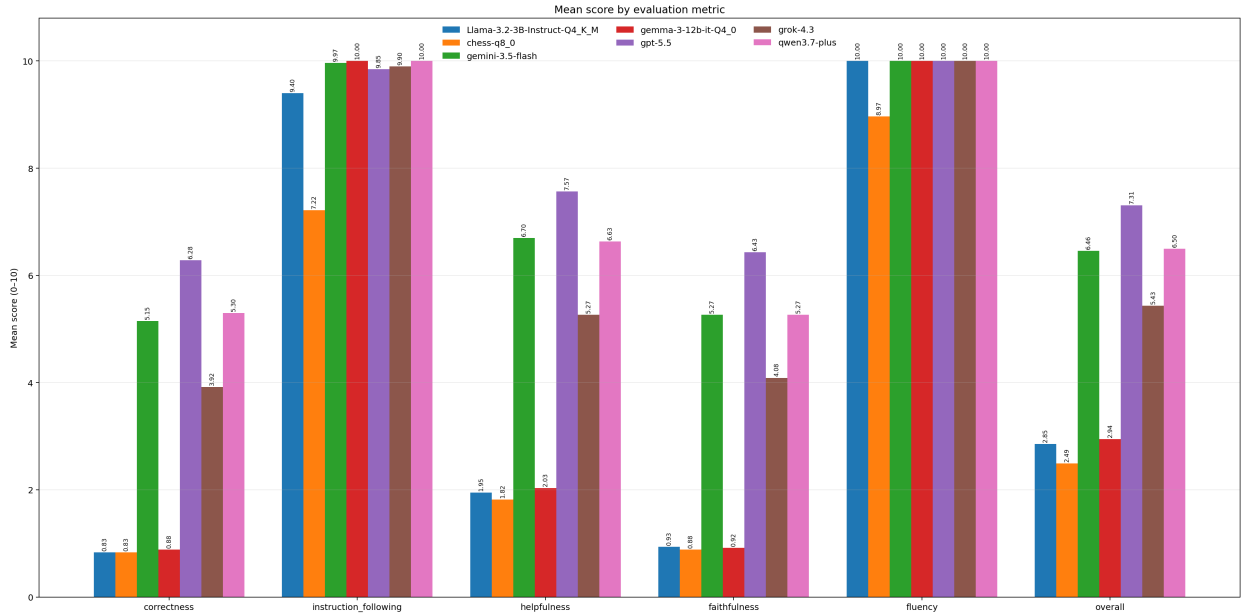
$$O = ۰٫۳۵C + ۰٫۲۵F + ۰٫۲۰H + ۰٫۱۰I + ۰٫۱۰L, \tag{۲}$$

که در آن C صحت، F وفاداری، H سودمندی، I پیروی از دستور و L روانی است. بنابراین ۶۰ درصد وزن کل به صحت و وفاداری اختصاص دارد. تمام ۴۲۰ داوری با موفقیت تجزیه شدند و هیچ نتیجه‌ای از داور کوچک Qwen در این گزارش استفاده نشده است.

۷ نتایج

جدول ۲: میانگین امتیاز داور Gemma 4 12B روی ۶۰ وضعیت برای هر مدل

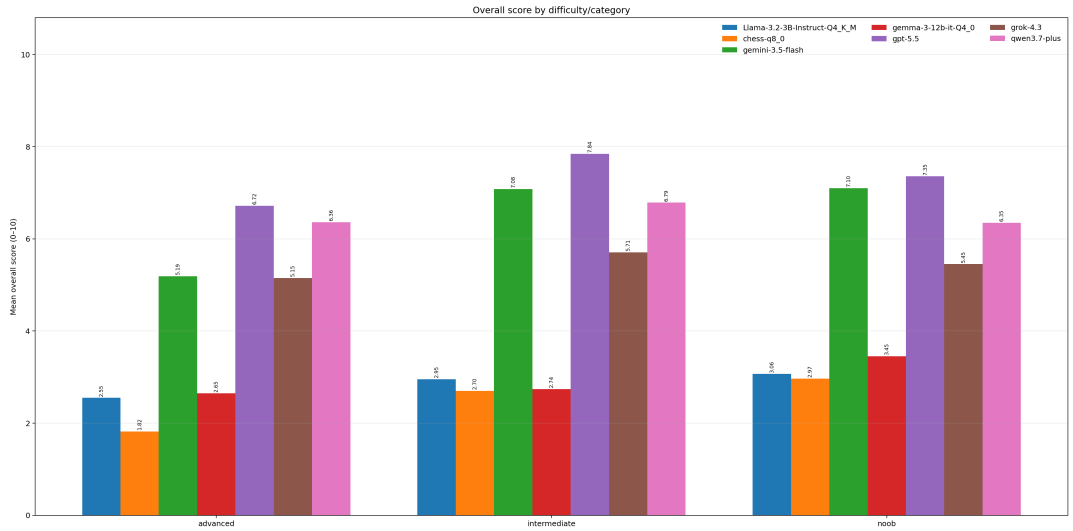
مدل پاسخ‌دهنده	صحت	پیروی	سودمندی	وفاداری	روانی	کل
GPT-5.5	۲۸.۶	۸۵.۹	۵۷.۷	۴۳.۶	۰۰.۱۰	۳۱.۷
Qwen3.7-Plus	۳۰.۵	۰۰.۱۰	۶۳.۶	۲۷.۵	۰۰.۱۰	۵۰.۶
Gemini-3.5-Flash	۱۵.۵	۹۷.۹	۷۰.۶	۲۷.۵	۰۰.۱۰	۴۶.۶
Grok-4.3	۹۲.۳	۹۰.۹	۲۷.۵	۰۸.۴	۰۰.۱۰	۴۴.۵
Gemma-3-12B-Instruct Q4	۸۸.۰	۰۰.۱۰	۰۳.۲	۹۲.۰	۰۰.۱۰	۹۵.۲
Llama-3.2-3B-Instruct Q4	۸۳.۰	۴۰.۹	۹۵.۱	۹۳.۰	۰۰.۱۰	۸۶.۲
Fine-tuned chess Q8	۸۳.۰	۲۲.۷	۸۲.۱	۸۸.۰	۹۷.۸	۴۹.۲



شکل ۱: میانگین معیارهای ارزیابی برای هفت مدل پاسخ‌دهنده

مدل GPT-5.5 با امتیاز ۳۱٫۷ در رتبه‌ی اول قرار دارد. پس از آن Qwen3.7-Plus و Gemini-3.5-Flash با امتیازهای نزدیک ۵۰٫۶ و ۴۶٫۶ قرار می‌گیرند. سه مدل محلی امتیاز کمتر از ۳ دارند. مدل شطرنج تنظیم‌شده نه‌تنها از مدل‌های میزبانی‌شده، بلکه از دو مدل محلی پایه نیز ضعیف‌تر است.

تفاوت میان روانی و صحت مهم‌ترین مشاهده‌ی جدول است. تقریباً همه‌ی مدل‌های بزرگ امتیاز روانی ۱۰ دارند، اما امتیاز صحت آن‌ها به‌طور محسوسی متفاوت است. مدل شطرنج تنظیم‌شده نیز متنی نسبتاً روان تولید می‌کند، ولی میانگین صحت ۸۳٫۰ و وفاداری ۸۸٫۰ نشان می‌دهد که متن آن غالباً با درس اصلی مرجع هم‌خوان نیست یا ادعاهای پشتیبانی‌نشده اضافه می‌کند.



شکل ۲: مقایسه‌ی امتیاز کل مدل‌ها در سه سطح دشواری

وضعیت‌های پیشرفته برای بیشتر مدل‌ها دشوارترند. برای نمونه، امتیاز Gemini-3.5-Flash از ۱۰٫۷ در گروه مبتدی به ۱۹٫۵ در گروه پیشرفته کاهش می‌یابد و امتیاز GPT-5.5 از ۳۶٫۷ به ۷۲٫۶ می‌رسد. عملکرد Qwen3.7-Plus در سه گروه پایدارتر است.

۸ بحث

۱۰۸ نقاط قوت

- **معماری قابل بازرسی:** خط‌های موتور، بهترین حرکت‌ها، وضعیت مات و ویژگی‌های صفحه مستقل از متن تولیدشده ذخیره می‌شوند؛
- **اجرای محلی:** مدل کوچک کوانتیزه‌شده و داور ۱۲ میلیارد پارامتری می‌توانند با llama.cpp اجرا شوند؛
- **تفکیک مسئولیت:** محاسبه‌ی شطرنج، استخراج ویژگی و تولید زبان سه جزء جدا هستند؛
- **ارزیابی بازتولیدپذیر:** هویت مدل، شناسه‌ی ردیف، مدل داور و امتیازهای جزء در مصنوعات خروجی ثبت می‌شوند؛
- **مقایسه‌ی منصفانه:** همه‌ی هفت مدل، ۶۰ درخواست یکسان را دریافت کرده‌اند.

۲۰۸ محدودیت‌ها

- تنها یک مدل داور استفاده شده است و سوگیری آن باید با داوری بازیکنان ریتینگ‌دار کالیبره شود؛
- هر پاسخ فقط با یک تفسیر مرجع مقایسه می‌شود، در حالی که ممکن است چند توضیح متفاوت ولی صحیح وجود داشته باشد؛
- معیار ۶۰ وضعیتی برای نتیجه‌گیری قطعی درباره‌ی اختلاف‌های کوچک کافی نیست؛
- تفسیر فقط انتقال یک حرکت را می‌بیند و ممکن است برنامه‌ی چندحرکتی یا زمینه‌ی کامل بازی را از دست بدهد؛
- امتیاز ۴۹٫۲ مدل تنظیم‌شده نشان می‌دهد آموزش روی کتاب‌های بدون برچسب برای اتصال صحیح متن به صفحه کافی نیست؛
- ویژگی‌های قطعی فعلی همه‌ی تاکتیک‌ها مانند آچمز، حمله‌ی کشفی یا اضافه‌بار مدافع را به‌صورت صریح تشخیص نمی‌دهند.

۳۰۸ مسیرهای آینده

مهم‌ترین گام بعدی ساخت داده‌ی جفت‌شده‌ی وضعیت و توضیح است. این داده می‌تواند با ترکیب تحلیل موتور، تولید اولیه‌ی یک مدل قوی و بازبینی بازیکن خبره ساخته شود. مطالعه‌ی حذف مؤلفه نیز باید سهم کتاب‌ها، خطوط Stockfish، ویژگی‌های

قطعی و روش زنجیره‌ای را جداگانه اندازه‌گیری کند. همچنین یک آزمایش کور انسانی برای محاسبه‌ی هم‌بستگی داور Gemma با بازیکنان ریتینگ‌دار ضروری است.

گسترش خروجی از توضیح پس از حرکت به برنامه‌ی چندشاخه، مسیر مهم دیگری است. در این حالت ارزیابی باید بسنجد که آیا کاربر می‌تواند بر اساس توضیح، در برابر پاسخ‌های متفاوت حریف حرکت مناسب را پیدا کند. چنین معیاری از شباهت متنی فراتر می‌رود و سودمندی واقعی آموزش را اندازه می‌گیرد.

۹ نتیجه‌گیری

بلاندر گارد یک خط لوله‌ی کامل برای تفسیر شطرنج ارائه می‌کند: تحلیل سه‌خطی Stockfish در عمق ۱۷، مقایسه‌ی قطعی دو صفحه، ساخت درخواست محدودشده و تولید متن با مدل کوچک کوانتیزه‌شده. این معماری اجرای محلی و بازرسی شواهد را ممکن می‌کند و ابزار ارزیابی آن می‌تواند مدل‌های محلی و میزبانی‌شده را تحت یک پروتکل مشترک مقایسه کند.

با این حال، نتیجه‌ی کمی ادعای حل‌شدن مسئله را تأیید نمی‌کند. مدل شطرنج تنظیم‌شده با امتیاز ۴۹٫۲، به‌ویژه در صحت و وفاداری، فاصله‌ی زیادی با مدل‌های قوی‌تر دارد. نتیجه‌ی اصلی این پژوهش آن است که وجود شواهد موتور شرط لازم است، اما تضمین نمی‌کند یک مدل کوچک آن شواهد را درست به زبان طبیعی تبدیل کند. آموزش وابسته به وضعیت، معیار بزرگ‌تر، مطالعه‌ی حذف مؤلفه و ارزیابی انسانی برای تبدیل این نمونه‌ی پژوهشی به یک مربی قابل اعتماد ضروری‌اند.

References

[1] Yngvi Björnsson. Chess and explainable AI. *ICGA Journal*, 46(2), 2024.

[2] David Bronstein. *Zurich International Chess Tournament, 1953*. Dover Publications, New York, NY, revised edition, 1979. Annotated games from the landmark candidates tournament.

[3] Irving Chernev. *Logical Chess: Move by Move*. Simon & Schuster, New York, NY, 1st edition, 1957. Detailed annotations explaining the reasoning behind every move.

[4] Langyuan Cui, Chun Kai Ling, and Hwee Tou Ng. Communicating chess strategies in natural language. *arXiv preprint arXiv:2607.11486*, 2026.

[5] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. *arXiv preprint arXiv:2305.14314*, 2023. Parameter-efficient fine-tuning method used in this work.

[6] Niklas Fiekas. python-chess: A chess library with move generation and validation, 2024. Python library for chess data processing.

[7] GGML Team. llama.cpp: Port of LLaMA model in C/C++, 2024. Inference framework for quantized model deployment.

[8] Google DeepMind. Gemma 4 Model Card, 2026. The 12B instruction model is used as the local evaluation judge.

[9] Harsh Jhamtani, Varun Gangal, Eduard Hovy, Graham Neubig, and Taylor Berg-Kirkpatrick. Learning to generate move-by-move commentary for chess games from large-scale social forum data. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Long Papers)*, pages 1661–1671, Melbourne, Australia, 2018. Association for Computational Linguistics.

[10] Jaechang Kim, Jinmin Goh, Inseok Hwang, Jaewoong Cho, and Jungseul Ok. Bridging the gap between expert and language models: Concept-guided chess commentary generation and evaluation. In *Proceedings of the 2025 Conference*

of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), pages 9497–9516, Albuquerque, New Mexico, 2025. Association for Computational Linguistics.

[11] Andrew Lee, David Wu, Emily Dinan, and Mike Lewis. Improving chess commentaries by combining language models with symbolic reasoning engines. *arXiv preprint arXiv:2212.08195*, 2022.

[12] Lichess.org. Lichess open database: Standard rated games, 2013. February 2013 PGN archive used to construct the evaluation strata.

[13] Aðalsteinn Pálsson and Yngvi Björnsson. Unveiling concepts learned by a world-class chess-playing agent. In *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence*, pages 4864–4872. International Joint Conferences on Artificial Intelligence Organization, 2023.

[14] Jeremy Silman. *How to Reassess Your Chess: Chess Mastery Through Chess Imbalances*. Siles Press, Los Angeles, CA, 4th edition, 2010. Comprehensive guide to positional play and strategic thinking.

[15] Stockfish Team. Stockfish: A free and strong chess engine, 2024. Open-source chess engine used for position evaluation.

[16] Mikhail Tal. *The Life and Games of Mikhail Tal*. Everyman Chess, London, UK, revised edition, 1997. Autobiography and annotated games of the eighth World Chess Champion.

[17] Siegbert Tarrasch. *The Game of Chess*. David McKay Company, Philadelphia, PA, 1st edition, 1935. Classic instructional text covering fundamental strategic principles.

[18] Hongyu Zang, Zhiwei Yu, and Xiaojun Wan. Automated chess commentator powered by neural chess engine. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 5952–5961, Florence, Italy, 2019. Association for Computational Linguistics.

[19] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, Hao Zhang, and Ion Stoica. Judging LLM-as-a-judge with MT-Bench and chatbot arena. *arXiv preprint arXiv:2306.05685*, 2023.